



PROPOSAL TUGAS BESAR ANALISIS BIG DATA Sains Data Institut Teknologi Sumatera 2026

Judul Tugas Besar

Analisis Tutupan Lahan Berbasis *Big Data Pipeline* untuk Pemantauan Ekosistem Daratan Menggunakan Arsitektur *Medallion*

Identitas Mahasiswa

No	Nama Peran	NIM	Username Github
1	Qois Olifio	123450067	QoisOlifio
2	Devyna Sonya Palupi Sanjaya	123450007	devynaass
3	Rosalia Siregar	123450036	rosaliasiregar
4	Zailani Satria	123450111	ZailaniSatria

Tema Tugas Besar

SDG 15 - Ekosistem Daratan

Ringkasan Proposal

Ringkasan proposal (maksimum 300 kata) berisi **Urgensi, tujuan, metode, dan luaran yang dihasilkan/targetkan**

Deforestasi dan degradasi ekosistem daratan merupakan ancaman serius terhadap keanekaragaman hayati global. Tujuan Pembangunan Berkelanjutan ke-15 (SDG 15) menargetkan perlindungan dan pemulihan ekosistem daratan, tetapi pemantauan tutupan lahan dalam skala besar masih terkendala oleh volume data citra satelit yang masif dan *pipeline* pemrosesan yang tidak terstruktur. Proyek ini bertujuan menjawab pertanyaan: "Apakah arsitektur *Medallion* berbasis Apache Spark dapat meningkatkan *throughput* pemrosesan data citra satelit Sentinel-2 untuk klasifikasi tutupan lahan dibandingkan *pipeline* sekuensial tradisional?" Metode yang digunakan adalah pembangunan *pipeline* Big Data tiga lapis (*Bronze–Silver–Gold*) dengan algoritma *Random Forest* sebagai model klasifikasi tutupan lahan. Dataset yang digunakan adalah *DeepGlobe Land Cover Classification Dataset* dari Kaggle yang berisi citra satelit beresolusi tinggi dengan tujuh kelas tutupan lahan. Luaran yang ditargetkan adalah: (1) *pipeline* Big Data *end-to-end* berbasis Spark yang dapat direproduksi, (2) model klasifikasi dengan akurasi $\geq 85\%$, dan (3) peta tutupan lahan dalam tabel yang dapat dikueri untuk mendukung pemantauan SDG 15.

Kata kunci

Isian 5 kata kunci yang dipisahkan dengan tanda titik koma (;)

Kata Kunci : *Land Cover Classification*; *Big Data Pipeline*; *Medallion Architecture*; *Random Forest*; *Remote Sensing*

Substansi Usulan

Petunjuk: Pengusul hanya diperkenankan mengisi di tempat yang telah disediakan (diberi warna) sesuai dengan petunjuk pengisian dan tidak diperkenankan untuk memodifikasi template menghapus setiap bagian.

A. RINGKASAN PAPER

Pilih satu paper yang paling relevan dengan proyek Anda dan tuliskan ringkasannya disini. Jangan melebihi 2 halaman untuk bagian ini.

Tabel 1. Rincian Paper yang diulas

Judul	Scalable Approach for High-Resolution Land Cover: A Case Study in the Mediterranean Basin
Penulis	Burgueño, A.M., Aldana-Martín, J.F., Vázquez-Pendón, M., et al.
Jurnal	Journal of Big Data, Springer Nature (Open Access)
Tahun	2023
URL	https://doi.org/10.1186/s40537-023-00770-z

1. LATAR BELAKANG

Gambarkan konteks paper: apa motivasi dan masalah yang dikemukakan para penulis? Masalah apa yang ingin mereka selesaikan atau pengetahuan apa yang ingin mereka temukan?

Penulis mengangkat masalah meningkatnya volume data citra satelit dari program Copernicus (Sentinel-2) dan ASTER yang tidak dapat lagi ditangani oleh *pipeline* pemrosesan data konvensional. Pemetaan tutupan lahan (*land cover mapping*) adalah tugas kritis untuk pemantauan lingkungan, pengelolaan hutan, dan pelaporan SDG, tetapi mengelola data satelit skala besar untuk wilayah luas seperti Mediterania membutuhkan infrastruktur komputasi terdistribusi. Para penulis ingin mengetahui apakah metodologi Big Data dapat menjadi solusi yang *scalable*, efisien, dan dapat direproduksi untuk menghasilkan peta tutupan lahan resolusi tinggi.

2. RINGKASAN KONTRIBUSI

Setiap paper memberikan sesuatu yang baru. Uraikan kontribusi utamanya - algoritma baru, hasil eksperimen, dataset baru, atau analisis baru

Paper ini memberikan kontribusi berupa: (a) metodologi *Big Data end-to-end* yang mencakup tahap pengunduhan data multi-satelit, prapemrosesan dalam lingkungan terdistribusi (Apache Spark), klasifikasi dengan *Random Forest* dan XGBoost, serta visualisasi hasil; (b) integrasi *explainable AI* (XAI/SHAP) untuk menjelaskan keputusan model secara transparan; dan (c) validasi metodologi pada studi kasus nyata berupa peta tutupan lahan Mediterania dari citra Sentinel-2 tahun 2021 dengan tujuh kelas tutupan (*urban*, pertanian, hutan, lahan basah, dll). Pendekatan ini terbukti lebih *scalable* dibandingkan *pipeline* tradisional karena menggunakan pemrosesan paralel berbasis Spark.

3. KETERBATASAN DAN DISKUSI

Identifikasi keterbatasan metodologi atau klaim generalisasi paper ini secara kritis. Apakah keterbatasan tersebut mengubah cara Anda menilai temuan paper ini?

Keterbatasan utama *paper* ini adalah studi kasus yang hanya diterapkan pada wilayah Mediterania sehingga generalisasi ke ekosistem tropis (seperti hutan hujan Asia Tenggara) memerlukan validasi lebih lanjut. Selain itu, *paper* tidak melaporkan metrik *throughput* secara eksplisit (misalnya baris/detik atau waktu ingesti), sehingga perbandingan kuantitatif kecepatan *pipeline* sulit dilakukan secara langsung. Ketergantungan pada data Sentinel-2 yang hanya tersedia sejak 2015 juga membatasi analisis perubahan tutupan lahan jangka panjang. Meskipun demikian, keterbatasan ini tidak mengurangi kontribusi metodologis *paper* secara substansial, justru membuka peluang untuk diadaptasi ke konteks wilayah tropis dalam proyek ini.

4. MENGAPA PAPER INI?

Dari sekian banyak paper, mengapa Anda memilih ini? Apa yang menarik dari topiknya? Setelah membacanya, apakah Anda mendapat apa yang diharapkan?

Paper ini dipilih karena merupakan satu-satunya *paper* di Journal of Big Data yang secara eksplisit menggabungkan *pipeline Big Data* terdistribusi dengan klasifikasi tutupan lahan untuk tujuan pemantauan lingkungan sehingga menjadikannya relevan secara teknis dan tematik dengan SDG 15. Topiknya menarik karena menjembatani dua domain: ilmu data dan ekologi. Setelah membaca *paper* ini, diperoleh pemahaman konkret tentang cara membangun *pipeline Spark* untuk data *remote sensing*, yang menjadi fondasi arsitektur proyek ini.

5. KONTEKS RISET YANG LEBIH LUAS

Hubungkan paper ini dengan tema-tema besar dalam Big Data: pemrosesan terdistribusi, manajemen kualitas data, skalabilitas, analitik real-time vs. batch, atau kesiapan data untuk machine learning. Apakah metode ini berpotensi diterapkan ke domain lain?

Paper ini berkaitan langsung dengan tema-tema besar dalam *Big Data*: pemrosesan terdistribusi (Apache Spark untuk data satelit bervolume besar), manajemen kualitas data (prapemrosesan multi-sumber dari Copernicus dan ASTER), dan kesiapan data untuk *machine learning* (*feature engineering* dari *band* spektral). Pendekatan *batch processing* yang digunakan relevan untuk dikonversi ke analitik *near real-time* menggunakan platform seperti Kafka. Metode ini berpotensi diterapkan ke domain lain seperti pemantauan bencana banjir, perubahan penggunaan lahan pertanian, atau deteksi *illegal mining*, semua memiliki dimensi ekosistem daratan yang relevan dengan SDG 15.

B. DESKRIPSI PROYEK

1. TUJUAN UTAMA

Rumuskan tujuan proyek Anda, idealnya sebagai pertanyaan ilmiah. Contoh: "Apakah arsitektur Medallion berbasis Spark dapat meningkatkan throughput pemrosesan data ekspor dibandingkan pipeline tradisional?" Jelaskan mengapa tujuan ini penting dan memungkinkan dicapai. Sebutkan tujuan sekunder (*stretch goal*) jika ada, dan hubungkan dengan paper yang Anda pilih.

"Apakah *pipeline Big Data* berbasis arsitektur Medallion (Apache Spark) dapat meningkatkan *throughput* pemrosesan data citra satelit untuk klasifikasi tutupan lahan dibandingkan *pipeline* sekuensial, sekaligus menghasilkan akurasi klasifikasi $\geq 85\%$ pada dataset *DeepGlobe*?"

Tujuan ini penting karena pemantauan tutupan hutan adalah indikator kunci SDG 15.1.1 (*forest area as proportion of total land area*). Tujuan sekunder (*stretch goal*): menambahkan *layer* deteksi perubahan tutupan lahan antar periode waktu, sebagaimana diinspirasi oleh metodologi *time-series* dalam *paper* yang dipilih.

2. STUDI KASUS / DOMAIN APLIKASI

Domain apa yang menjadi fokus proyek Anda? Berikan contoh konkret: apa input datanya dan apa output analitik yang diharapkan? Jika sudah dijelaskan dalam ringkasan paper, maka buat lebih detail disini.

Domain: Pemantauan ekosistem daratan melalui klasifikasi tutupan lahan berbasis citra satelit.

Input: Citra satelit beresolusi tinggi (format GeoTIFF/JPEG) dari dataset *DeepGlobe*, berisi 7 kelas tutupan lahan (*urban*, pertanian, padang rumput, hutan, lahan basah, lahan, air).

Proses: Ingesti ke *Bronze layer* → normalisasi *band* spektral di *Silver layer* → ekstraksi fitur + klasifikasi *Random Forest* di *Gold layer*.

Output: Tabel klasifikasi piksel per kelas tutupan lahan yang dapat dikueri, beserta metrik akurasi model (OA, *F1-score* per kelas).

3. DATASET

Sebutkan dataset yang akan digunakan (sumber, ukuran, format). Jelaskan prapemrosesan yang direncanakan. Jika mengumpulkan data sendiri, jelaskan caranya dan estimasi waktu yang diperlukan.

Atribut	Detail
Nama Dataset	DeepGlobe Land Cover Classification Dataset
Sumber	Kaggle:kaggle.com/datasets/balraj98/deepglobe-land-cover-classification-dataset
Ukuran	±3,4 GB; 803 gambar satelit resolusi 2448×2448 piksel
Format	JPEG (citra) + CSV (label <i>mask</i> per piksel)
Kelas	7 kelas: urban, pertanian, padang rumput, hutan, lahan basah, tanah, air
Prapemrosesan	Normalisasi nilai piksel RGB, <i>resize patch</i> menjadi tile 256×256, konversi ke format Parquet untuk Spark, pembersihan tile dengan cloud cover >20%

Dataset ini 100% publik dan langsung dapat diunduh dari Kaggle tanpa registrasi institusi.

4. ARSITEKTUR DAN TEKNOLOGI

Jelaskan komponen teknis utama yang akan digunakan dan bagaimana mereka berinteraksi. Jika menggunakan Medallion Architecture, jelaskan setiap lapisannya. Tunjukkan mana yang diimplementasikan sendiri dan mana yang menggunakan konfigurasi yang sudah ada.

Menggunakan **Medallion Architecture** tiga lapis:

- **Bronze Layer:** Ingesti raw data (GeoTIFF/JPEG) menggunakan Apache Spark + HDFS. Data disimpan tanpa transformasi.

- **Silver Layer:** Prapemrosesan terdistribusi yang meliputi normalisasi *band* spektral, pemotongan citra (*tiling*), dan *filtering* kualitas. *Output:* Parquet *files*.

- **Gold Layer:** *Feature engineering* (perhitungan NDVI, statistik tekstur) + *training* model *Random Forest* (MLlib Spark). *Output:* tabel klasifikasi dan model terlatih.

Komponen utama: Apache Spark 3.x, HDFS/MinIO, Jupyter Notebook, Python (PySpark, scikit-learn, rasterio). Diimplementasikan sendiri: Skrip preprocessing citra, *pipeline Medallion*, *training Random Forest*. Menggunakan konfigurasi tersedia: Docker image Spark bitnami, MinIO sebagai *object storage* lokal.

5. METODE PEMBANDING (BASELINE)

Metode apa yang digunakan sebagai pembandingan? Misalnya: pemrosesan sekuensial tanpa distribusi, pipeline sederhana satu lapisan, atau implementasi yang telah dipublikasikan. Jelaskan apakah diimplementasikan sendiri atau diambil dari sumber lain.

Baseline: *pipeline* sekuensial satu lapis menggunakan scikit-learn pada Python tanpa distribusi Spark, seluruh data diproses secara lokal di satu mesin. Diimplementasikan sendiri. Metrik throughput (gambar/detik) dan akurasi dibandingkan langsung dengan *pipeline* Medallion-Spark.

6. EVALUASI

Tentukan minimal satu metrik kuantitatif yang jelas. Contoh metrik yang umum digunakan: throughput (baris/detik), latensi end-to-end pipeline, akurasi prediksi (RMSE/MAE untuk regresi, silhouette score untuk clustering), atau rasio kompresi penyimpanan. Sebutkan nilai acuan (baseline score) yang ada di literatur atau yang Anda targetkan.

Tabel 2. Metrik evaluasi yang direncanakan

Metrik	Acuan (Baseline)	Target
Throughput ingesti (baris/dtk)	0,8 (sekuensial, 1 node)	$\geq 3,0$ (Spark, 3 node)
Latensi pipeline end-to-end	~60 menit (sekuensial)	≤ 20 menit
Overall Accuracy klasifikasi	78% (Logistic Regression)	$\geq 85\%$ (Random Forest)
F1-Score kelas Hutan	0,72 (baseline)	$\geq 0,82$

7. TANTANGAN ETIS DAN RISIKO SOSIAL

Tulis satu paragraf yang membahas: (A) minimal dua tantangan etis atau risiko sosial yang spesifik untuk proyek Anda - misalnya privasi data, potensi bias dalam model prediksi yang memengaruhi kebijakan, transparansi algoritma terhadap pemangku kepentingan, atau ketergantungan pada data yang tidak representatif - dan (B) strategi mitigasi yang spesifik dan praktis. Bagian ini dinilai berdasarkan kedalaman pemikiran.

Proyek ini menghadapi dua tantangan etis utama. Pertama, potensi **bias model** akibat ketidakseimbangan kelas dalam dataset **DeepGlobe** dimana kelas "*urban*" dan "*air*" memiliki proporsi lebih kecil dibanding kelas "*pertanian*", sehingga model dapat memprediksi hutan sebagai lahan pertanian dengan akurasi rendah per kelas. Bias ini berbahaya jika hasil klasifikasi digunakan untuk kebijakan konservasi, karena dapat memberikan gambaran yang salah tentang kondisi hutan. Strategi mitigasi: menggunakan teknik *oversampling* (SMOTE) dan *class-weighted loss function*, serta melaporkan **F1-score** per kelas, bukan hanya akurasi keseluruhan. Kedua, terkait **transparansi algoritma** di mana mekanisme pengambilan keputusan model **Random Forest** sulit dijelaskan kepada pemangku kepentingan non-teknis (seperti pembuat kebijakan kehutanan). Mitigasi: mengintegrasikan **SHAP** (*SHapley Additive exPlanations*) untuk mengidentifikasi fitur *band* spektral mana yang paling memengaruhi prediksi setiap kelas, sebagaimana dilakukan dalam *paper* acuan.

REFERENSI

Gunakan format referensi IEEE. Sitasi disusun dan ditulis berdasarkan sistem nomor sesuai dengan urutan pengutipan. Hanya pustaka yang disitasi pada usulan penelitian yang dicantumkan dalam Referensi.

- [1] A. M. Burgueño, J. F. Aldana-Martín, M. Vázquez-Pendón, et al., "Scalable approach for high-resolution land cover: a case study in the Mediterranean Basin," *Journal of Big Data*, vol. 10, no. 91, 2023, doi: 10.1186/s40537-023-00770-z.
- [2] B. Raj, "DeepGlobe Land Cover Classification Dataset," Kaggle, 2020. [Online]. Available: <https://www.kaggle.com/datasets/balraj98/deepglobe-land-cover-classification-dataset>
- [3] H. Guo, "SDG 15, Life on Land," in *Big Earth Data in Support of the Sustainable Development Goals (2022)*, Springer, Singapore, 2024, doi: 10.1007/978-981-97-3278-4_8.