

ANALISIS TUTUPAN LAHAN BERBASIS *BIG DATA PIPELINE* UNTUK PEMANTAUAN EKOSISTEM DARATAN MENGGUNAKAN ARSITEKTUR *MEDALLION*

Qois Olifio; Devyna Sonya Palupi Sanjaya; Rosalia Siregar ; Zailani Satria

Program Studi Sains Data, Fakultas Sains
Institut Teknologi Sumatera, Lampung Selatan, Indonesia
itera.ac.id
qois.123450067@student.itera.ac.id



The creation is distributed under the Creative Commons Attribution-NonCommercial 4.0 International License.

Abstract

Terrestrial ecosystems face increasingly severe threats from deforestation and massive land conversion, making land cover monitoring a key indicator within the SDG 15 framework. This study aimed to develop an end-to-end Big Data pipeline based on the Medallion Architecture (Bronze-Silver-Gold) using Apache PySpark 4.0.2 for land cover classification, while demonstrating the effectiveness of Apache Parquet as an intermediate storage layer for reducing memory consumption in resource-constrained computing environments. The DeepGlobe Land Cover Classification Dataset comprising five land cover classes was used as the benchmark dataset. Data processing was implemented through three layered stages, namely raw data ingestion (Bronze), RGB pixel-to-tabular transformation via color mapping (Silver), and feature consolidation with Random Forest classification using Spark MLlib (Gold). The Medallion Architecture achieved a 322% improvement in ingestion throughput and reduced pipeline latency from 58.40 minutes to 18.20 minutes compared to the sequential baseline, while peak driver memory consumption was reduced from 7.62 GB to 2.84 GB through Parquet-based columnar storage. The Random Forest model attained an Overall Accuracy of 87%, with the Water class achieving the highest F1-Score of 0.93 due to its homogeneous and contrasting spectral characteristics, and the Rangeland class recording the lowest at 0.80 due to spectral similarity with agricultural land in standard RGB imagery lacking a Near-Infrared channel. The developed pipeline proves to be both computationally efficient and spatially competitive, establishing it as a reliable instrument for digital terrestrial ecosystem monitoring in support of SDG 15 targets.

Keywords: Apache spark, Big Data Pipeline, Land Cover Classification, Medallion Architecture, Random Forest.

Intisari

Ekosistem daratan menghadapi ancaman deforestasi dan alih fungsi lahan yang semakin masif, sehingga pemantauan tutupan lahan menjadi indikator kunci dalam kerangka SDG 15. Penelitian ini bertujuan membangun *pipeline* Big Data *end-to-end* berbasis Arsitektur Medallion (Bronze-Silver-Gold) menggunakan Apache PySpark 4.0.2 untuk klasifikasi tutupan lahan, sekaligus membuktikan efektivitas penyimpanan Apache Parquet sebagai *intermediate layer* dalam mereduksi konsumsi memori pada lingkungan komputasi terbatas. Dataset yang digunakan adalah DeepGlobe Land Cover Classification Dataset dengan lima kelas tutupan lahan. Pemrosesan data diimplementasikan melalui tiga lapisan bertingkat, yaitu ingesti data mentah (Bronze), transformasi piksel RGB ke format tabular melalui *color mapping* (Silver), serta konsolidasi fitur dan klasifikasi menggunakan *Random Forest* berbasis *Spark MLlib* (Gold). Arsitektur Medallion berhasil meningkatkan *throughput* ingesti sebesar 322% dan mereduksi latensi *pipeline* dari 58,40 menit menjadi 18,20 menit dibandingkan *baseline* sekuensial, sementara konsumsi memori *driver* puncak berkurang dari 7,62 GB menjadi 2,84 GB melalui penyimpanan kolumnar Parquet. Model *Random Forest* mencapai akurasi keseluruhan sebesar 87%, dengan *F1-Score* tertinggi pada kelas Perairan sebesar 0,93 dan terendah pada kelas Padang Rumput sebesar 0,80 akibat kemiripan spektral dengan Lahan Pertanian pada citra RGB standar yang tidak memiliki saluran *Near-Infrared*. *Pipeline* yang dikembangkan terbukti unggul secara komputasi sekaligus kompetitif secara klasifikasi sebagai instrumen pemantauan ekosistem daratan digital guna mendukung target SDG 15.

Kata Kunci: *Apache Spark, Arsitektur Medallion, Big Data Pipeline, Klasifikasi Tutupan Lahan, Random Forest.*

PENDAHULUAN

Ekosistem daratan menghadapi tekanan yang semakin berat akibat deforestasi, alih fungsi lahan, dan degradasi lingkungan yang terjadi secara masif di berbagai belahan dunia. Dalam kerangka Tujuan Pembangunan Berkelanjutan ke-15 (SDG 15 - *Life on Land*), pemantauan tutupan lahan menjadi salah satu indikator kunci untuk mengukur keberhasilan perlindungan dan pemulihan ekosistem daratan. Pemetaan tutupan lahan dari data penginderaan jauh merupakan pendekatan yang efektif karena mampu menyediakan informasi spasial permukaan bumi secara cepat, luas, dan berulang, sehingga menjadi instrumen penting dalam mendukung pemantauan ekosistem secara berkelanjutan.

Seiring dengan berkembangnya teknologi satelit, volume data citra yang dihasilkan oleh program penginderaan jauh seperti Copernicus terus meningkat secara eksponensial. Kondisi ini menciptakan tantangan komputasi yang nyata, di mana *pipeline* pemrosesan data konvensional yang bersifat sekuensial tidak lagi mampu menangani data dalam skala besar secara efisien. Burgueno et al. [1] menunjukkan bahwa pendekatan *Big Data* berbasis *Apache Spark* mampu memproses data citra satelit resolusi tinggi untuk pemetaan tutupan lahan kawasan Mediterania secara lebih skalabel dibandingkan *pipeline* tradisional. Namun, penerapan arsitektur *Medallion* secara eksplisit sebagai kerangka *pipeline* berlapis untuk klasifikasi tutupan lahan pada *dataset benchmark* publik masih belum banyak dieksplorasi.

Berdasarkan kesenjangan tersebut, penelitian ini bertujuan membangun *pipeline Big Data end-to-end* berbasis Arsitektur *Medallion* (*Bronze-Silver-Gold*) menggunakan *Apache Spark* untuk klasifikasi tutupan lahan pada *DeepGlobe Land Cover Classification Dataset* [2]. Selain menghasilkan model klasifikasi yang kompetitif, penelitian ini juga bertujuan membuktikan bahwa strategi penyimpanan *Parquet* sebagai *intermediate layer* mampu mengurangi konsumsi RAM secara signifikan pada lingkungan komputasi terbatas, sehingga *pipeline* yang dibangun dapat dijalankan pada infrastruktur *cloud* yang terjangkau dan mendukung pemantauan ekosistem daratan sesuai target SDG 15.

METODOLOGI PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif berbasis pemrosesan data citra satelit berskala besar dengan tujuan mengklasifikasi tutupan lahan ekosistem daratan secara otomatis. Desain penelitian dirancang dengan mengikuti paradigma *big data pipeline* yang memisahkan tahapan ingesti, transformasi, dan pemodelan data secara terstruktur menggunakan arsitektur *Medallion*. Arsitektur *Medallion* terdiri dari lapisan-lapisan bertingkat yang masing-masing memberi masukan bagi lapisan berikutnya hingga menghasilkan data yang siap digunakan [3]. Kerangka kerja komputasi yang digunakan adalah *Apache PySpark* versi 4.0.2 yang dijalankan di *Google Colaboratory* dengan konfigurasi kluster lokal dan alokasi memori *driver* sebesar 8 GB. *PySpark* dipilih karena dapat melakukan pemrosesan data secara terdistribusi di dalam memori (*in-memory computing*), sehingga mampu menangani volume data piksel citra satelit yang sangat besar dengan kecepatan dan efisiensi yang tinggi [4].

Sumber data penelitian ini adalah *DeepGlobe Land Cover Dataset*, sebuah *dataset* citra satelit resolusi tinggi yang terdiri dari pasangan citra satelit dalam format JPEG dan masker anotasi tutupan lahan dalam format PNG. Setiap piksel pada masker telah dianotasi ke dalam salah satu dari lima kelas tutupan lahan yaitu, Pemukiman/Perkotaan (*cyan*), Lahan Pertanian (*kuning*), Padang Rumput/Semak Belukar (*magenta*), Perairan (*biru*), dan Area Tidak Dikenali (*putih*). Pemantauan dan klasifikasi tutupan lahan melalui citra satelit merupakan pendekatan yang efektif karena kemampuannya menyediakan informasi spasial permukaan bumi secara cepat, luas, dan akurat [5]. Pemetaan tutupan lahan dari data penginderaan jauh menjadi langkah krusial dalam mendukung pemantauan ekosistem daratan dan ketahanan pangan secara berkelanjutan [6]. Data disimpan dan diakses melalui *Google Drive* selama proses eksperimen berlangsung.

Teknik pengumpulan data dilakukan dengan mengunduh *dataset DeepGlobe* dan menyimpannya pada direktori *Google Drive* yang terstruktur. Citra satelit dan masker anotasi yang bersesuaian diorganisasikan dalam direktori yang terpisah, kemudian dibaca menggunakan *library OpenCV* dengan konversi format warna dari BGR ke RGB untuk memastikan konsistensi representasi piksel sebelum masuk ke tahap *pipeline*.

Teknik analisis data dalam penelitian diimplementasikan melalui tiga lapisan pemrosesan bertingkat sesuai arsitektur *Medallion*. Arsitektur ini sejalan dengan konsep pemrosesan dan analitik data besar (BPA) yang mencakup lapisan pengumpulan, penyimpanan, pemrosesan, analitik hingga lapisan aplikasi [3]. Pertama, *Bronze Layer*, data mentah berupa citra satelit dan masker anotasi dibaca langsung dari penyimpanan tanpa modifikasi apa pun, merepresentasikan data dalam kondisi aslinya sebagai pondasi *pipeline*. Kedua, *Silver Layer*, masker anotasi berwarna diterjemahkan menjadi label kelas numerik melalui mekanisme *color mapping* berbasis pencocokan nilai piksel RGB. Setiap piksel citra direpresentasikan sebagai baris data tabular yang memuat tiga atribut fitur, yaitu nilai kanal merah (R), hijau (G), dan biru (B), beserta label kelasnya. Data tabular hasil transformasi disimpan dalam format *Apache Parquet* untuk mengoptimalkan penggunaan memori selama proses komputasi berlangsung. Ketiga, *Gold Layer*, fitur R, G, B dikonsolidasikan menjadi satu vektor fitur tunggal menggunakan *VectorAssembler* dari pustaka *MLlib* PySpark. *Dataset* kemudian dipartisi menjadi 80% data latih dan 20% data uji menggunakan pemisahan acak dengan nilai *seed* sebesar 42, sehingga hasil eksperimen dapat direproduksi secara konsisten [4].

Algoritma yang digunakan adalah *Random Forest*, metode *ensemble learning* yang membangun sejumlah pohon keputusan secara paralel dan mengagregasi hasilnya melalui mekanisme *majority vote* untuk meningkatkan akurasi serta mengurangi *overfitting* [6]. Model dikonfigurasi dengan 20 pohon keputusan (*numTrees*=20) dan kedalaman pohon maksimum sebesar 10 (*maxDepth*=10). Pemilihan algoritma *Random Forest* didasarkan pada kemampuannya menangani data berdimensi tinggi, mengatasi multikolinearitas, serta ketidakpekaan terhadap *overfitting* yang menjadikannya sangat cocok untuk data penginderaan jauh [6]. Evaluasi performa model dilakukan menggunakan metrik akurasi keseluruhan (*overall accuracy*) yang dihitung melalui *MulticlassMetrics* dari pustaka *MLlib* PySpark pada data uji [4]. Hasil prediksi model divisualisasikan pada potongan citra berukuran 256×256 piksel untuk memungkinkan perbandingan kualitatif antara masker *ground truth* dan hasil prediksi model secara visual.

HASIL DAN PEMBAHASAN

Pengujian repositori data berlapis dan fungsionalitas arsitektur *Medallion* dilakukan untuk menjawab pertanyaan ilmiah mengenai efisiensi pemrosesan data penginderaan jauh berskala besar.

Evaluasi sistem difokuskan pada dua metrik performa komputasi utama, yaitu *throughput* kecepatan ingesti data citra satelit dan akumulasi latensi waktu eksekusi *pipeline end-to-end*. Nilai performa komputasi ini diukur secara komparatif dengan membandingkan arsitektur *Medallion* berbasis Apache Spark terhadap *pipeline* sekuensial tradisional yang berjalan pada lingkungan node tunggal (*single-node*). Rincian kuantitatif hasil pengujian dimensi efisiensi komputasi terdistribusi tersebut disajikan secara terstruktur pada Table 1.

Table 1. Core Computational Efficiency and Pipeline Performance Comparison

Metrics Evaluation	Sequential Baseline (Single-Node scikit-learn)	Medallion Architecture (Apache Spark Local Cluster)
Ingestion Throughput (images/sec)	0.81	3.42
End-to-End Pipeline Latency (minutes)	58.40	18.20
Peak Driver Memory Usage (GB)	7.62	2.84

Berdasarkan data pada Tabel 1, implementasi Arsitektur *Medallion* menggunakan Apache PySpark terbukti meningkatkan *throughput* ingesti data citra secara signifikan, yaitu sebesar 322% lebih cepat dibandingkan metode sekuensial konvensional (dari 0,81 menjadi 3,42 *images/sec*). Peningkatan ini dimungkinkan oleh kemampuan PySpark dalam mempartisi data piksel citra secara paralel memanfaatkan seluruh inti logis (*logical cores*) pada kluster mesin lokal (*local[*]*), sehingga sejumlah berkas citra dapat diproses secara konkuren dalam satu siklus eksekusi. Berbeda dengan pendekatan *baseline* yang memproses setiap citra secara linier satu per satu (*single-threaded*), mekanisme pemrosesan terdistribusi PySpark menjadi fondasi utama kecepatan yang jauh lebih tinggi, terutama saat berhadapan dengan ribuan berkas citra satelit resolusi tinggi seperti pada DeepGlobe Land Cover Classification Dataset.

Latensi eksekusi *pipeline end-to-end* berhasil direduksi secara dramatis dari 58,40 menit pada *baseline* sekuensial menjadi hanya 18,20 menit pada Arsitektur *Medallion*, merepresentasikan penurunan latensi sebesar 68,8%. Reduksi yang signifikan ini tidak semata-mata bersumber dari paralelisasi komputasi, melainkan secara krusial dipengaruhi oleh strategi penyimpanan antara

(*intermediate storage*) menggunakan format Apache Parquet pada Silver Layer. Pemisahan fungsionalitas dari tahap pengumpulan (Bronze), penyimpanan terstruktur (Silver), hingga analisis siap pakai (Gold) memberikan fondasi aliran data besar yang konsisten dan andal. Format Parquet yang bersifat kolumnar (*column-oriented*) memungkinkan kompresi data yang lebih efisien karena nilai dalam satu kolom bersifat homogen dalam tipe dan distribusinya, serta mendukung mekanisme *predicate pushdown* sehingga Gold Layer hanya perlu membaca kolom yang dibutuhkan untuk komputasi tanpa harus memuat seluruh baris data.

Konsumsi memori *driver* puncak berhasil ditekan dari 7,62 GB pada *baseline* sekuensial menjadi hanya 2,84 GB pada Arsitektur Medallion, mewakili reduksi sebesar 62,7%. Mengingat total alokasi memori *driver* yang dikonfigurasi hanya sebesar 8 GB, pendekatan *baseline* hampir menghabiskan seluruh kapasitas yang tersedia (97,6%), sehingga menempatkan *pipeline* pada risiko *OutOfMemoryError* yang tinggi saat menangani dataset berukuran lebih besar. Sebaliknya, Arsitektur Medallion menjaga konsumsi memori hanya pada 35,5% dari total alokasi, memberikan ruang yang cukup bagi operasi Spark lainnya dan memastikan stabilitas eksekusi. Efisiensi memori ini dicapai melalui dua mekanisme berlapis: pertama, konversi data tabular piksel ke berkas Parquet yang dilanjutkan dengan pembebasan variabel Python secara eksplisit pada Silver Layer; kedua, mekanisme *lazy evaluation* PySpark yang hanya mengeksekusi transformasi pada partisi data yang aktif diproses, sedangkan data yang belum dibutuhkan tetap tersimpan di penyimpanan persisten. Efisiensi manajemen memori berlapis ini membuktikan bahwa pemanfaatan ekosistem *Data Lake* terstruktur mampu mereduksi beban komputasi data tidak terstruktur secara masif pada infrastruktur *cloud* dengan alokasi memori terbatas.

Model *Random Forest Classifier* berbasis *Spark MLlib* dievaluasi menggunakan 20% data uji independen yang dipartisi dari DeepGlobe Land Cover Classification Dataset dengan nilai *seed* tetap sebesar 42 untuk memastikan reproduktibilitas eksperimen. Model dikonfigurasi dengan 20 pohon keputusan (*numTrees*=20) dan kedalaman pohon maksimum sebesar 10 (*maxDepth*=10). Evaluasi mencakup metrik presisi, *recall*, dan *F1-Score* per kelas tutupan lahan, serta akurasi keseluruhan (*Overall Accuracy*). Hasil lengkap disajikan pada Tabel 2.

Table 2. Quantitative Land Cover Classification Performance Matrix

Land Cover Class	Precision	Recall	F1-Score
Urban / Perkotaan (Cyan)	0.88	0.84	0.86
Agriculture / Lahan Pertanian (Kuning)	0.89	0.91	0.90
Rangeland / Padang Rumput (Magenta)	0.81	0.79	0.80
Water / Perairan (Biru)	0.94	0.92	0.93
Overall Accuracy (OA)	-	-	0.87

Berdasarkan Tabel 2, model *Random Forest Classifier* berbasis *Spark MLlib* berhasil mencatatkan *Overall Accuracy* sebesar 87% pada data uji independen. Pencapaian ini membuktikan bahwa fitur spektral sederhana berupa tiga kanal warna RGB sudah memadai untuk membedakan kelas-kelas tutupan lahan yang memiliki karakteristik warna kontras, sekaligus mengkonfirmasi efektivitas *Spark MLlib* dalam mengeksekusi perhitungan ensemble pohon keputusan secara paralel di atas memori (*in-memory processing*) untuk pemrosesan *machine learning* berskala besar.

Jika ditinjau per kelas, kelas Perairan (*Water*) memperoleh *F1-Score* tertinggi sebesar 0,93 dengan presisi 0,94 dan *recall* 0,92. Kinerja superior ini bersumber dari karakteristik spektral unik area perairan pada citra RGB: badan air secara konsisten menampilkan nilai kanal biru (B) yang dominan dan jauh lebih tinggi dibandingkan kanal merah (R) maupun hijau (G), membentuk distribusi piksel yang sangat berbeda dari kelas-kelas lainnya. Homogenitas dan kontras spektral yang tinggi ini menciptakan batas keputusan (*decision boundary*) yang jelas bagi pohon-pohon keputusan dalam *ensemble*, sehingga hampir tidak terjadi tumpang tindih distribusi piksel antara kelas Perairan dengan kelas lainnya.

Kelas Lahan Pertanian menduduki posisi kedua dengan *F1-Score* 0,90 (presisi 0,89, *recall* 0,91). Nilai *recall* yang sedikit lebih tinggi dari presisi mengindikasikan adanya kecenderungan model mengklasifikasikan sebagian piksel dari kelas lain — khususnya Padang Rumput — sebagai Lahan Pertanian, yang konsisten dengan rendahnya *recall* kelas Padang Rumput. Kelas Perkotaan mencatatkan *F1-Score* 0,86 (presisi 0,88, *recall* 0,84), di mana nilai presisi yang lebih tinggi dari *recall* mengindikasikan model cukup selektif dalam

menentukan piksel sebagai area perkotaan, namun masih melewati sebagian piksel perkotaan pada kawasan transisi yang memiliki respons spektral bervariasi.

Nilai *F1-Score* terendah terdapat pada kelas Padang Rumput (*Rangeland*) sebesar 0,80, dengan presisi 0,81 dan *recall* 0,79. Analisis matriks kesalahan mengungkap bahwa sumber utama misklasifikasi adalah tumpang tindih prediksi dengan kelas Lahan Pertanian: vegetasi alami pada padang rumput dan tanaman budidaya pada lahan pertanian yang berada dalam fase pertumbuhan aktif sama-sama menampilkan dominasi kanal hijau (G) yang tinggi dalam citra RGB standar. Keterbatasan ini bersifat fundamental dan berkaitan langsung dengan tidak tersedianya saluran spektral *Near-Infrared* (NIR) pada citra RGB JPEG. Dalam penginderaan jauh multispektral, vegetasi aktif memiliki pantulan sangat tinggi pada panjang gelombang NIR, sehingga indeks NDVI yang dihitung dari rasio NIR–Merah mampu membedakan jenis dan kerapatan vegetasi secara jauh lebih presisi. Tanpa saluran NIR, model hanya bergantung pada variasi dalam spektrum tampak yang secara inheren ambigu antara kedua kelas tersebut.

Untuk memvalidasi keandalan model secara spasial dan kualitatif, dilakukan inferensi visual langsung pada potongan citra uji beresolusi 256×256 piksel yang diambil dari koordinat awal (0,0). Hasil komparasi antara citra satelit asli, masker *ground truth*, dan proyeksi prediksi model dipaparkan pada Gambar 1.



Gambar 1. Perbandingan Spasial Citra Satelit, Masker *Ground Truth*, dan Output Prediksi *Random Forest*

Berdasarkan Gambar 1, masker *ground truth* pada potongan yang diuji seluruhnya menampilkan kelas Padang Rumput (Magenta), mengindikasikan bahwa area potongan tersebut didominasi oleh satu kelas tunggal. Sementara itu, hasil prediksi model menampilkan campuran kelas Padang Rumput (Magenta) dan Perkotaan (Cyan), yang menunjukkan adanya misklasifikasi pada sebagian piksel. Kondisi ini konsisten dengan nilai *recall* kelas Perkotaan sebesar 0,84 pada Tabel 2, yang

mengindikasikan model masih menghasilkan sejumlah *false positive* pada area dengan tekstur permukaan yang menyerupai karakteristik piksel perkotaan. Perlu dicatat bahwa pemilihan koordinat potongan pada titik (0,0) menghasilkan sampel yang tidak merepresentasikan keragaman kelas secara menyeluruh, sehingga validasi visual pada satu potongan ini tidak dapat digeneralisasi sebagai ukuran performa spasial keseluruhan model. Meskipun demikian, akurasi keseluruhan sebesar 87% yang diukur pada 20% data uji independen yang representatif tetap menjadi ukuran performa model yang sah dan menyeluruh, menegaskan bahwa *pipeline* Big Data berbasis Arsitektur Medallion yang dikembangkan layak sebagai instrumen pemantauan ekosistem daratan digital guna mendukung target SDG 15.

KESIMPULAN

Penelitian ini berhasil membangun *pipeline* Big Data *end-to-end* berbasis Arsitektur Medallion (Bronze–Silver–Gold) menggunakan Apache PySpark 4.0.2 untuk klasifikasi tutupan lahan pada DeepGlobe Land Cover Classification Dataset. Arsitektur Medallion terbukti meningkatkan *throughput* ingesti data sebesar 322% dan mereduksi latensi *pipeline end-to-end* dari 58,40 menit menjadi 18,20 menit dibandingkan *pipeline* sekuensial konvensional berbasis *scikit-learn*. Penerapan format Apache Parquet pada Silver Layer berhasil menekan konsumsi memori *driver* puncak dari 7,62 GB menjadi 2,84 GB, membuktikan bahwa *pipeline* ini layak dijalankan pada infrastruktur *cloud* terjangkau dengan alokasi memori terbatas.

Model *Random Forest Classifier* berbasis *Spark MLlib* mencapai akurasi keseluruhan sebesar 87%, dengan kelas Perairan memperoleh *F1-Score* tertinggi sebesar 0,93 akibat karakteristik spektralnya yang homogen dan kontras pada citra RGB. Kelas Padang Rumput mencatatkan *F1-Score* terendah sebesar 0,80 akibat kemiripan spektral dengan kelas Lahan Pertanian pada citra RGB standar yang tidak memiliki saluran *Near-Infrared*, sehingga model kesulitan membedakan vegetasi alami dari tanaman budidaya hanya berdasarkan nilai piksel spektrum tampak.

Validasi spasial melalui inferensi visual pada potongan citra 256×256 piksel mengkonfirmasi pola misklasifikasi yang konsisten dengan analisis kuantitatif: sebagian piksel Padang Rumput diklasifikasikan sebagai Perkotaan pada area dengan tekstur permukaan yang memiliki respons spektral serupa. Temuan ini selaras dengan nilai *ground truth* kelas Perkotaan sebesar 0,84 pada Tabel 2 dan memperkuat interpretasi bahwa

keterbatasan spektral RGB, khususnya absennya saluran *recall Near-Infrared* merupakan batas atas performa yang dapat dicapai tanpa data multispektral. Akurasi keseluruhan 87% pada data uji independen membuktikan bahwa *pipeline* Big Data berbasis Arsitektur Medallion yang dikembangkan terbukti unggul secara komputasi sekaligus menghasilkan klasifikasi yang kompetitif sebagai instrumen pemantauan ekosistem daratan digital guna mendukung target SDG 15.

DAFTAR PUSTAKA

- [1] A. M. Burgueño *et al.*, "Scalable approach for high-resolution land cover: a case study in the Mediterranean Basin," *J. Big Data*, vol. 10, no. 1, Dec. 2023, doi: 10.1186/s40537-023-00770-z.
- [2] H. Guo, *Big Earth Data in Support of the Sustainable Development Goals (2022)—The Belt and Road*. Singapore: Springer Nature Singapore Pte Ltd., 2024.
- [3] A. Cucus, R. Yuli Endra, Y. Aprilinda, and Y. Yanu Dharmawan, "Lapisan Arsitektur Big Data dalam Kajian Studi Pustaka," *Jurnal Sistem Informasi dan Telematika (Telekomunikasi, Multimedia dan Informatika)*, vol. 12, p. 22, Jun. 2021.
- [4] A. A. Kurniawan, M. Mustikasari, and P. Korespondensi, "Evaluasi Kinerja MLib Apache Spark Pada Klasifikasi Berita Palsu Dalam Bahasa Indonesia," *Jurnal Teknologi Infoemasi dan Ilmu Komputer (JTIK)*, vol. 9, no. 3, pp. 489–500, Jun. 2022, doi: 10.25126/jtiik.202293538.
- [5] D. Marlina, "STRING (Satuan Tulisan Riset dan Inovasi Teknologi) Klasifikasi Tutupan Lahan Pada Citra Sentinel-2 Kabupaten Kuningan Dengan NVDI dan Algoritme Random Forest," Aug. 2022. [Online]. Available: <https://earthexplorer.usgs.gov/>.
- [6] K. Tutupan *et al.*, "Klasifikasi Tutupan Lahan Berdasarkan Random Forest Algorithm Menggunakan Cloud Computing Platform," Mar. 2022.